



2.1.0.

对伯努利分布.

$$P(x|\mu) = \mu^x (1-\mu)^{1-x}$$

$$E(x) = \mu \quad \text{var}(x) = \mu(1-\mu)$$

对于二项分布 $P(m|N, \mu) = \binom{N}{m} \mu^m (1-\mu)^{N-m}$

$$E(m) = N\mu \quad \text{var}(m) = N(1-\mu)\mu.$$

伯努利分布中对 μ 的最大似然估计.

$$\mu_{ML} = \frac{1}{N} \sum_{n=1}^N x_n$$

∴ 假设扔一个硬币 3 次且均正面朝上.

则 $N=m=3$ ∴ $\mu_{ML}=1$ 最大似然的结果将预测所有未来的观测值都是正面向上, 这是最大似然中过拟合现象的一个例子.

2.1.1

共轭性: 选择与概率密度函数形式相似的先验概率分布.

那么后验概率分布 (正比于似然函数和先验的乘积) 就会有与先验分布相同的函数形式

对 $P(x|\mu) = \mu^x (1-\mu)^{1-x}$ 取先验概率分布函数.

$$P(m|N, \mu) = \binom{N}{m} \mu^m (1-\mu)^{N-m}$$

$$\text{Beta}(\mu, a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \mu^{a-1} (1-\mu)^{b-1}.$$

其中 $\Gamma(x) = \int_0^{\infty} u^{x-1} e^{-u} du$. 保证归一化.

$$E(\mu) = \frac{a}{a+b} \quad \text{var}(\mu) = \frac{ab}{(a+b)^2 (a+b+1)}$$

此时后验概率分布 = $\text{Beta}(\mu|a, b) \cdot \binom{N}{m} \mu^m (1-\mu)^{N-m}$


$$P(\mu|m, l, a, b) = \frac{\Gamma(m+a)\Gamma(l+b)}{\Gamma(m+a+l+b)} \mu^{m+a-1} (1-\mu)^{l+b-1}.$$

∴ a 和 b 分别为 $x=1$ 和 $x=0$ 的观测数. (不一定是整数).




每次取得一个观测值, 然后在每次观测值后更新当前的后验分布。(更新方法是让当前的后验分布与新观测值的似然函数相乘, 然后归一化, 获得新的修正后的后验分布, 即将每次得到的后验分布作为下一次观测的先验分布。


顺序方法学习, 可以应用于实时学习场景中, 在实时学习的场景中, 输入为一个稳定且持续的数据流, 模型必须在观测所有数据之前就进行预测。



$$a=2 \quad b=2$$



$$a=1 \quad b=1$$



$$a=3 \quad b=2$$

贝叶斯的结果和最大似然的结果在 $N \rightarrow \infty$ 会统一到一起, 对于有限规模的数据集, μ 的后验均值总是位于先验均值和 μ 的最大似然估计之间, 随着观测数据增多, 后验概率的不确定性会持续下降。

